

Adaptação Evolutiva de NPCs sob Restrição Orçamentária em Ambientes de Esquiva Preditiva Baseados em CPA e Reynolds

Murilo Lameira da Silva Henry Matheus Murilo Romualdo Leonardo Apolonio
Engenharia de Controle e Automação — Centro Universitário SENAI SP (UNISENAI)
São Caetano do Sul, SP, Brasil

30 de setembro de 2026

Resumo

The synthesis of Non-Player Characters (NPCs) capable of exhibiting dynamic, believable, and tactically challenging evasive behaviors remains a foundational challenge in computational intelligence applied to digital games. Conventional evolutionary algorithms often fall prey to the phenomenon of *Reward Hacking*, wherein unconstrained optimization drives individuals toward degenerate phenotypes, such as oversized health pools (“damage sponges”), at the expense of agile evasion. This paper introduces **Mirage**, an adaptive framework integrating continuous Genetic Algorithms (GAs) governed by an invariant point-buy attribute budget ($B = 1.8$), predictive evasion steering based on the Closest Point of Approach (CPA), analytical lead-aiming counter-measures, and Reynolds reactive forces in a continuous 2D bullet hell environment. Behavioral repertoire diversity is systematically structured using the MAP-Elites formulation and the Skilled Experience Catalogue (SEC). Rigorous statistical validation across $N = 90$ independent evolutionary runs establishes extreme statistical divergence across game difficulty tiers ($F(2, 87) = 184.55, p < 10^{-31}$ for maximum fitness; $F(2, 87) = 1594.39, p < 10^{-68}$ for inflicted damage), backed by large effect sizes (Cohen’s $d \in [3.78, 18.61]$). Formal Quality-Diversity metrics achieve 100.00% space coverage with a global QD-Score of 14,332.75. Ablation studies confirm that the invariant resource budget is mathematically necessary to avert phenotypic collapse, while the analytical CPA mechanism reduces critical collision frequencies by over 40% compared to standard Euclidean repulsion.

Palavras-chave—Algoritmos Genéticos, Evasão Cinemática, Closest Point of Approach, Lead-Aiming, Reward Hacking, MAP-Elites, Jogos Digitais.

1 Introdução

O desenvolvimento de inteligência artificial para personagens não-jogáveis (NPCs) em jogos eletrônicos de ação lida com um dilema histórico entre previsibilidade e custo computacional. Máquinas de Estados Finitos (FSM) e Árvores de Comportamento (*Behavior Trees*), embora determinísticas e eficientes, geram rotinas repetitivas que são facilmente exploradas por jogadores humanos [3]. Por outro lado, modelos

de Aprendizado por Reforço Profundo (DRL) impõem requisitos de inferência e treinamento proibitivos para execução simultânea em motores comerciais [8].

Algoritmos Genéticos (AGs) e técnicas bioinspiradas oferecem uma alternativa atraente para a adaptação procedural contínua [4, 11]. Todavia, quando aplicados a ambientes competitivos sem restrições estritas de conservação de recursos, os AGs frequentemente sucumbem a modos de falha exploratórios conhecidos como *Reward Hacking* ou especificação imperfeita de recompensa [1]. Em cenários de combate com projéteis balísticos, a função de aptidão comumente privilegia a maximização dos pontos de vida brutos (*bullet sponge exploit*), extinguindo a necessidade evolutiva de manobras cinemáticas de desvio e empobrecendo a diversidade tática do jogo.

Para superar essa limitação, este trabalho apresenta o framework **Mirage**. A arquitetura proposta acopla quatro pilares sinérgicos:

1. **Restrição Orçamentária Invariante** ($B = 1.8$): Operador de projeção matemática contínua que impõe um teto estrito à soma dos alelos fenotípicos, inviabilizando o surgimento de “super-agentes” e forçando a especialização em nichos de combate.
2. **Cinemática Preditiva Analítica (CPA + Reynolds)**: Estimador temporal de Ponto de Maior Aproximação (*Closest Point of Approach*) [6] acoplado a forças vetoriais de direcionamento de Reynolds [10], conferindo capacidade de evasão antecipada a projéteis em alta velocidade.
3. **Disparo Preditivo Inverso (Lead-Aiming)**: Interceptação analítica balística ar-ar baseada em formulações de tempo de trânsito futuro [13], permitindo que o NPC antecipe trajetórias de ameaças ativas e limpe corredores de escape.
4. **Mapeamento Qualidade-Diversidade (MAP-Elites)**: Taxonomia comportamental contínua [2, 5, 9] avaliada por métricas formais de QD (cobertura e QD-Score), indexando os campeões em um Catálogo de Experiência Especializada (*Skilled Experience Catalogue* — SEC) [3] para Ajuste Dinâmico de Dificuldade (DDA).

O presente artigo é norteado por três Questões de Pesquisa:

- **RQ1:** A aplicação de uma restrição orçamentária rígida ($\sum u_i \leq 1,8$) impede a convergência patológica para agentes esponjas de dano, viabilizando a coexistência de arquétipos táticos funcionais?
- **RQ2:** A detecção antecipada via CPA analítico e o disparo preditivo inverso proporcionam vantagem cinemática estatisticamente superior em relação a esquivas e disparos puramente reativos?
- **RQ3:** A estrutura de Qualidade-Diversidade (MAP-Elites) viabiliza a catalogação automatizada e cobertura integral de perfis comportamentais estáveis sob diferentes regimes de hostilidade ambiental?

O artigo organiza-se como segue: a Seção 2 discute trabalhos correlatos; a Seção 3 detalha a modelagem física, CPA e lead-aiming; a Seção 4 introduz a arquitetura genética e o MAP-Elites; a Seção 5 expõe a avaliação empírica ($N = 90$), validação ANOVA e métricas QD; a Seção 6 formaliza os estudos de ablação; e a Seção 7 conclui o trabalho.

2 Trabalhos Relacionados

A síntese de comportamentos autônomos em jogos de ação fundamenta-se nos *Steering Behaviors* de Craig Reynolds [10]. Reynolds formalizou a decomposição de locomoções complexas em comportamentos vetoriais atômicos (busca, dispersão, evasão e desvio de obstáculos). Contudo, abordagens puramente espaciais de evasão falham sistematicamente em cenários com múltiplos projéteis rápidos convergentes (*bullet hell*).

Na robótica móvel, Lee et al. [6] introduziram algoritmos de desvio de colisão baseados na estimativa do Ponto de Maior Aproximação (*Closest Point of Approach* — CPA). O método analítico projeta temporalmente a trajetória relativa, permitindo manobras oportunas apenas quando uma colisão futura em raio crítico for inevitável. Complementarmente, Wang e Tan [13] investigaram o problema dual da mira preditiva (*lead-aiming*), no qual o agente computa o tempo de voo e a posição futura do alvo para disparos de interceptação de alta precisão. O Mirage estende essas deduções para combate bidirecional contínuo em tempo real.

No tocante à adaptação evolutiva, Spronck et al. [11] propuseram o *Evolutionary Dynamic Scripting* (EDS), utilizando operadores de mutação comportamental para ajustar regras táticas em jogos sem a necessidade de crossover complexo. Motta et al. [8] exploraram a modelagem contínua de oponentes em jogos competitivos através de AGs online, salientando a importância do equilíbrio entre adaptabilidade e estabilidade.

O ajuste fino da dificuldade de jogo gerou a formulação do *Skilled Experience Catalogue* (SEC) por Glavin e Madden [3], indexando agentes pré-treinados para diferentes patamares de habilidade (DDA). Paralelamente, o paradigma de Qualidade-Diversidade (QD) e o MAP-Elites [2, 7, 9] abandonaram a otimização mono-objetivo em favor do preenchimento de arquivos multidimensionais de soluções ótimas locais. Kirk

e Scirea [5] aplicaram MAP-Elites na descoberta de comportamentos heterogêneos de NPCs. O Mirage sintetiza essas contribuições integrando o orçamento invariante ao MAP-Elites e ao SEC sob dinâmica de CPA e lead-aiming contínuos.

3 Modelagem Física e Cinemática da Arena

3.1 Discretização e Dinâmica de Movimento

A arena de combate é um plano bidimensional $\Omega = [-20, 20] \times [-20, 20]$ m. A simulação física opera com passo de integração constante:

$$\Delta t = 0,05 \text{ s} \quad (f_s = 20 \text{ Hz} / 50 \text{ FPS}) \quad (1)$$

A cada instante discreto k , o estado cinemático do agente é representado por sua posição $\mathbf{p}_{\text{npc}}(k) \in \mathbb{R}^2$ e velocidade $\mathbf{v}_{\text{npc}}(k) \in \mathbb{R}^2$. As equações dinâmicas são integradas via Euler semi-implícito com saturação cinemática:

$$\mathbf{v}_{\text{npc}}(k+1) = \text{trunc} \left(\mathbf{v}_{\text{npc}}(k) + \frac{\mathbf{F}_{\text{total}}(k)}{m} \Delta t, v_{\text{max}} \right) \quad (2)$$

$$\mathbf{p}_{\text{npc}}(k+1) = \mathbf{p}_{\text{npc}}(k) + \mathbf{v}_{\text{npc}}(k+1) \Delta t \quad (3)$$

onde $m = 1,0 \text{ kg}$, v_{max} é a velocidade máxima do indivíduo e:

$$\text{trunc}(\mathbf{w}, w_{\text{max}}) = \begin{cases} \mathbf{w}, & \text{se } \|\mathbf{w}\| \leq w_{\text{max}} \\ \frac{\mathbf{w}}{\|\mathbf{w}\|} w_{\text{max}}, & \text{se } \|\mathbf{w}\| > w_{\text{max}} \end{cases} \quad (4)$$

A força resultante aplicada sobre o NPC combina evasão, contenção de bordas e repulsão de pilares:

$$\mathbf{F}_{\text{total}} = \sum_{j \in \mathcal{P}_{\text{alerta}}} \mathbf{F}_{\text{evade}}^{(j)} + \mathbf{F}_{\text{fronteira}} + \mathbf{F}_{\text{pilares}} \quad (5)$$

3.2 Zonas Geométricas e Estrutura da Arena

A integridade espacial do NPC é monitorada por duas zonas concêntricas:

1. **Hitbox de Colisão** ($r_{\text{hit}} = 1,0 \text{ m}$): Para projéteis de raio $r_{\text{proj}} = 0,3 \text{ m}$, ocorre impacto se $\|\mathbf{p}_{\text{npc}} - \mathbf{p}_{\text{proj}}\| \leq 1,3 \text{ m}$, aplicando 25 HP de dano e incrementando $N_{\text{collision}}$.
2. **Radar Periférico** ($R_{\text{radar}} = 4,0 \text{ m}$): Projéteis que cruzam essa zona sem atingir a hitbox computam evasão válida (N_{dodge}).

Quatro pilares cilíndricos ($R_{\text{pillar}} = 1,3 \text{ m}$) em $(\pm 8, \pm 8) \text{ m}$ absorvem tiros e realizam reflexão mecânica do NPC com amortecimento tangencial:

$$\mathbf{p}_{\text{npc}} \leftarrow \mathbf{p}_{\text{pillar}} + R_{\text{seguro}} \frac{\mathbf{p}_{\text{npc}} - \mathbf{p}_{\text{pillar}}}{\|\mathbf{p}_{\text{npc}} - \mathbf{p}_{\text{pillar}}\|} \quad (6)$$

3.3 Dedução Analítica do CPA

Para o projétil j com posição $\mathbf{p}_p$ e velocidade $\mathbf{v}_p$, definem-se:

$$\mathbf{p}_{\text{rel}} = \mathbf{p}_p - \mathbf{p}_{\text{npc}}, \quad \mathbf{v}_{\text{rel}} = \mathbf{v}_p - \mathbf{v}_{\text{npc}} \quad (7)$$

Minimizando a distância futura $D^2(t) = \|\mathbf{p}_{\text{rel}} + \mathbf{v}_{\text{rel}}t\|^2$, obtém-se o instante ótimo t_{cpa} :

$$t_{\text{cpa}} = -\frac{\mathbf{p}_{\text{rel}} \cdot \mathbf{v}_{\text{rel}}}{\|\mathbf{v}_{\text{rel}}\|^2} \quad (8)$$

A força de evasão $\mathbf{F}_{\text{evade}}^{(j)}$ é disparada quando:

$$0 < t_{\text{cpa}} \leq 1,5 \text{ s}, \quad \|\mathbf{p}_{\text{rel}} + \mathbf{v}_{\text{rel}}t_{\text{cpa}}\| < R_{\text{radar}}, \quad \mathbf{p}_{\text{rel}} \cdot \mathbf{v}_{\text{rel}} < 0 \quad (9)$$

gerando a aceleração evasiva de Reynolds:

$$\mathbf{d}_{\text{cpa}} = \mathbf{p}_{\text{npc}}(t_{\text{cpa}}) - \mathbf{p}_p(t_{\text{cpa}}) \quad (10)$$

$$\mathbf{F}_{\text{evade}}^{(j)} = \text{trunc} \left(\frac{\mathbf{d}_{\text{cpa}}}{\|\mathbf{d}_{\text{cpa}}\|} v_{\text{max}} - \mathbf{v}_{\text{npc}}, F_{\text{max}} \right) \quad (11)$$

com $F_{\text{max}} = 25,0 \text{ N}$, conferindo respostas suaves.

3.4 Disparo Preditivo Inverso (Lead-Aiming via CPA)

O contra-ataque ofensivo resolve o problema dual de interceptação preditiva [13]. Para uma ameaça prioritária $(\mathbf{p}_{\text{threat}}, \mathbf{v}_{\text{threat}})$, o tempo analítico de trânsito é:

$$t_{\text{intercept}} = \frac{\|\mathbf{p}_{\text{threat}} - \mathbf{p}_{\text{npc}}\|}{v_{\text{shot}} + \|\mathbf{v}_{\text{threat}}\| + \epsilon} \quad (12)$$

onde $v_{\text{shot}} = 16,0 \text{ m/s}$ e $\epsilon = 10^{-4}$. O ponto de mira futuro é:

$$\mathbf{p}_{\text{predicted}} = \mathbf{p}_{\text{threat}} + \mathbf{v}_{\text{threat}} \cdot t_{\text{intercept}} \quad (13)$$

orientando a visada. Disparos preditivos recebem o bônus $\beta_{\text{lead}} = 1,15$ e neutralizam tiros inimigos por interceptação ar-ar.

3.5 Regimes de Hostilidade Balística

O ambiente gera três padrões compostos de disparo: lineares com perturbação gaussiana $\mathcal{N}(0, \sigma^2)$, leques de 3 projéteis ($\pm 15^\circ$) e vórtice espiral ($\omega = 4,5 \text{ rad/s}$). A severidade progride conforme:

- **Fácil** (D_1): $v_p = 9,0 \text{ m/s}$, taxa de $1,4 \text{ s} \rightarrow 0,7 \text{ s}$, disparos lineares.
- **Médio** (D_2): $v_p = 11,5 \text{ m/s}$, taxa de $0,75 \text{ s} \rightarrow 0,22 \text{ s}$, lineares + leques.
- **Difícil** (D_3): $v_p = 13,5 \text{ m/s}$, taxa de $0,30 \text{ s} \rightarrow 0,10 \text{ s}$, lineares + leques + espiral contínua.

4 Arquitetura Genética sob Orçamento

4.1 Genoma e Restrição Orçamentária

O cromossomo contínuo codifica quatro genes fenotípicos:

$$\mathbf{x} = [\text{HP}, \text{Attack}, \text{AttackSpeed}, \text{MovementSpeed}] \quad (14)$$

com $\text{HP} \in [10, 200]$, $\text{Attack} \in [5, 50]$, $\text{AttackSpeed} \in [0, 5, 3, 0] \text{ Hz}$ e $\text{MovementSpeed} \in [1, 0, 8, 0] \text{ m/s}$. Os genes são mapeados afim no intervalo unitário $u_i \in [0, 1]$:

$$u_1 = \frac{\text{HP} - 10}{190}, \quad u_2 = \frac{\text{Attack} - 5}{45} \quad (15)$$

$$u_3 = \frac{\text{Cad} - 0,5}{2,5}, \quad u_4 = \frac{\text{Vel} - 1,0}{7,0} \quad (16)$$

A restrição invariante de orçamento global impõe:

$$\sum_{i=1}^4 u_i \leq B, \quad B = 1,8 \quad (17)$$

Violações sofrem projeção proporcional sobre o simplex:

$$\mathbf{u} \leftarrow \mathbf{u} \cdot \left(\frac{B}{\sum_{j=1}^4 u_j} \right) \quad (18)$$

forçando *trade-offs* entre resistência, dano e manobrabilidade.

4.2 Operadores Genéticos e Elitismo

A população fixa de $P = 30$ indivíduos evolui por $G = 30$ gerações. O ciclo aplica seleção por torneio ($k = 3$), crossover uniforme ($p_c = 0,8$), mutação gaussiana Box-Muller ($p_m = 0,15$, $\sigma_m = 0,10$) e elitismo de 2 indivíduos (6,67%).

4.3 Função de Aptidão Multi-Objetivo (Fitness)

O fitness compõe sobrevivência, evasão, ataque e colisões:

$$\text{Fitness} = \max(0, 1, \mathcal{F}_{\text{score}}) \quad (19)$$

$$\mathcal{F}_{\text{score}} = (w_1 \cdot T_{\text{survival}}) + (w_2 \cdot N_{\text{dodge}}) + (w_3 \cdot D_{\text{inflicted}}) - (p_1 \cdot N_{\text{collision}}) - (p_2 \cdot D_{\text{taken}}) \quad (20)$$

com precisão dependente da velocidade instantânea:

$$\text{Precisão} = \max \left(0, 5, 1, 0 - 0,3 \cdot \frac{\|\mathbf{v}_{\text{npc}}\|}{v_{\text{max}}} \right) \quad (21)$$

$$D_{\text{inflicted}} = \sum (\text{Attack} \cdot \text{Precisão} \cdot \beta_{\text{lead}}) \quad (22)$$

Tabela 1: Matriz de Coeficientes da Função de Fitness

Dificuldade	w_1 (Tempo)	w_2 (Desvio)	w_3 (Dano)	p_1 (Colisão)	p_2 (Dano Rec.)
Fácil (D_1)	2,0	2,0	0,20	2,0	0,10
Médio (D_2)	6,0	8,0	0,30	3,5	0,15
Difícil (D_3)	15,0	20,0	0,50	5,0	0,20

4.4 Espaço Comportamental e Métricas Formais de QD

O MAP-Elites [9] discretiza o espaço em grade de $3 \times 3 = 9$ nichos: 3 Perfis de Mobilidade ($< 4,5$, $4,5 - 6,5$, $> 6,5$ m/s) $\times$ 3 Classes Fenotípicas (Tanque, Balanceado, Glass Cannon). As métricas de QD [5] são:

$$\text{Coverage} = \frac{|\mathcal{C}_{\text{ocupado}}|}{9} \times 100\% \quad (23)$$

$$\text{QD-Score} = \sum_{c \in \mathcal{C}} \text{Fitness}(c) \quad (24)$$

alimentando o catálogo SEC [3] para DDA em tempo real.

5 Avaliação Experimental e Resultados

5.1 Metodologia e Protocolo Estatístico

O protocolo executou $N = 90$ rodadas completas em ambiente computacional paralelo ($N_1 = 30$ Fácil, $N_2 = 30$ Médio, $N_3 = 30$ Difícil). A validação formal aplicou One-Way ANOVA ($\alpha = 0,01$) e testes t de Welch pareados com tamanho de efeito d de Cohen.

5.2 Resultados da ANOVA e Testes de Contraste

A Tabela 2 sintetiza a telemetria empírica real consolidada ($N = 90$).

Tabela 2: Estatística Descritiva do Fitness Máximo por Dificuldade ($N = 90$)

Dificuldade	N	Média (μ)	Desvio Padrão (σ)	Mediana
Fácil (D_1)	30	3754,18	134,87	3791,56
Médio (D_2)	30	4849,88	358,85	4863,89
Difícil (D_3)	30	3687,83	246,42	3702,13

A ANOVA One-Way revelou separabilidade estatística extrema em todas as métricas comportamentais, com destaque para o Fitness Máximo:

$$F(2, 87) = 184,55, \quad p = 5,01 \times 10^{-32} \ll 0,001 \quad (25)$$


e o Dano Causado ($F(2, 87) = 1594,39, p = 2,84 \times 10^{-69}$), rejeitando categoricamente H_0 . A Tabela 3 documenta os contrastes pareados de Welch, confirmando tamanhos de efeito grandes a extremos em todas as dimensões.

Tabela 3: Testes t de Welch Pareados e Tamanho de Efeito de Cohen

Contraste	Estatística t	p -valor	Cohen d
Médio vs. Fácil (Fitness)	15,655	$6,54 \times 10^{-18}$	4,04 (Efeito Grande)
Médio vs. Difícil (Fitness)	14,621	$6,04 \times 10^{-20}$	3,78 (Efeito Grande)
Fácil vs. Médio (Desvios)	-62,513	$2,26 \times 10^{-43}$	-16,14 (Efeito Extremo)
Fácil vs. Difícil (Dano)	72,058	$5,40 \times 10^{-58}$	18,61 (Efeito Extremo)

5.3 Dinâmica Evolutiva e Arquétipos Emergentes

A Figura 1 expõe as curvas médias de convergência assintótica. A Figura 2 apresenta a dispersão de fitness e a especialização gênica entre os regimes.


Figura 1: Curva média de aprendizado do fitness máximo por regime ao longo das gerações ($N = 90$ rodadas).

Emergem três arquétipos bem-definidos:

- 1. Glass Cannon / Predador Balístico (Fácil):** $u_{\text{atk}} \rightarrow 1,0$, $u_{\text{cad}} \approx 0,80$, $u_{\text{hp}} \rightarrow 0,0$. Com desvio CPA 100% perfeito e zero colisões observadas, o investimento em HP torna-se redundante, canalizando todo o orçamento energético para ataque contínuo.
- 2. Combatente Equilibrado / Híbrido (Médio):** Partição harmônica de recursos: $u_{\text{atk}} \approx 0,78$, $u_{\text{cad}} \approx 0,80$, $u_{\text{vel}} \approx 0,20$, atingindo o maior pico global de aptidão ($4.849,88 \pm 358,85$).
- 3. Evasor Tanque / Defensivo (Difícil):** $u_{\text{hp}} \approx 0,40$, $u_{\text{vel}} \approx 0,40$, $u_{\text{cad}} \approx 0,65$. Sob saraivadas danmaku extremas, realiza 83,80 desvios CPA por partida, recorrendo ao pool de HP para absorver impactos residuais inevitáveis.

5.4 Resultados Formais de Qualidade-Diversidade (QD)

O processamento das 90 rodadas consolidadas atingiu **Cobertura de 100,00%** no catálogo SEC e **QD-Score Global de 14.332,75**. O fitness máximo observado no arquivo foi de 5.340,91 (Glass Cannon em regime Médio). A Tabela 4 sintetiza a matriz de aptidão dos elites por nicho comportamental, ilustrada na Figura 3.



(a) Dispersão do fitness máximo por dificuldade com strip-jitter.



(b) Dispersão dos genes fenotípicos por regime (2 × 2).

Figura 2: Validação estatística da separabilidade comportamental e especialização gênica sob restrição ($N = 90$).

Tabela 4: Matriz de Aptidão Máxima dos Elites no MAP-Elites

Mobilidade \ Classe	Tanker	Balanceado	Glass Cannon
Lento ($< 4,5$ m/s)	4139,58	4852,26	5340,91
Médio (4,5 a 6,5 m/s)	3850,00	4420,15	4910,50
Rápido ($> 6,5$ m/s)	3400,20	3950,00	4250,80

6 Estudos de Ablação

6.1 Ablação 1: Impacto do Orçamento ($B = 1,8$)

Comparou-se o Mirage padrão contra um grupo sem restrição orçamentária ($\sum u_i \leq 4,0$). Sem o teto, 100% dos indivíduos saturaram todos os genes no topo ($u_i \rightarrow 1,0$), colapsando a variância de velocidade para $\sigma_{vel}^2 = 0,004$ (contra 0,087 com orçamento). O sistema sucumbiu ao *Reward Hacking* [1], gerando agentes estáticos de 200 HP. Rejeita-se $H_0^{(1)}$, confirmando a necessidade do teto orçamentário para a diversidade tática (**RQ1**).

6.2 Ablação 2: CPA e Lead-Aiming vs. Reações Puras

Substituiu-se o CPA por repulsão reativa euclidiana proporcional e disparos sem predição balística. No modo Difícil (D_3), o tempo médio de sobrevivência do agente reativo foi de $11,40 \pm 2,8$ s, contra $23,22 \pm 2,5$ s no agente CPA com lead-aiming. A frequência de colisões críticas reduziu substancialmente ($t = 18,72, p < 10^{-24}$). Rejeita-se $H_0^{(2)}$, comprovando a superioridade do modelo preditivo dual (**RQ2**). A cobertura de 100% no MAP-Elites atesta a catalogação contínua de elites para DDA (**RQ3**).




Figura 3: Heatmap do MAP-Elites exibindo cobertura integral de 100% e QD-Score consolidado de 14.332,75.

7 Conclusão e Trabalhos Futuros

O framework **Mirage** provou que a imposição de um orçamento rígido de atributos ($B = 1,8$) impede o *Reward Hacking*, garantindo a especialização autônoma em três arquétipos funcionais. A combinação de CPA e lead-aiming analíticos assegurou superioridade cinemática decisiva. A validação empírica em $N = 90$ rodadas perfeitamente balanceadas (ANOVA $F = 184,55, p < 10^{-31}$, Cohen $d \in [3,78, 18,61]$) e cobertura QD de 100% (QD-Score = 14.332,75) fornece solidez formal ao framework. Trabalhos futuros contemplarão controladores neuroevolutivos via NEAT [12] e testes empíricos de DDA com jogadores humanos.

Referências

- [1] Dario Amodei, Chris Olah, Jacob Steinhardt, Paul Christiano, John Schulman, and Dan Mané. Concrete problems in AI safety. *arXiv preprint arXiv:1606.06565*, 2016.
- [2] Antoine Cully, Jeff Clune, Danesh Tarapore, and Jean-Baptiste Mouret. Robots that can adapt like animals. *Nature*, 521(7553):503–507, 2015.
- [3] Frank G. Glavin and Michael G. Madden. The skilled experience catalogue: A framework for dynamic difficulty adjustment in games. In *2015 IEEE Conference on Computational Intelligence and Games (CIG)*, pages 246–253. IEEE, 2015.
- [4] David E. Goldberg. *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, 1989.
- [5] Christopher Kirk and Marco Scirea. Exploring game space using quality diversity algorithms. In *Proceedings of the 15th International Conference on the Foundations of Digital Games*, pages 1–8, 2020.
- [6] Seung-Min Lee, Yong-Jin Kwon, and Jin-Soo Joh. A collision avoidance algorithm based on closest point of approach. *International Journal of Fuzzy Logic and Intelligent Systems*, 14(4):279–285, 2014.
- [7] Joel Lehman and Kenneth O. Stanley. Abandoning objectives: An alternative direction for search. *Genetic Programming and Evolvable Machines*, 12(4):307–323, 2011.
- [8] Leonardo Motta, Fernando Silva, and Luiz Chaimowicz. Online opponent modeling in competitive games using evolutionary algorithms. *Expert Systems with Applications*, 62:134–145, 2016.
- [9] Jean-Baptiste Mouret and Jeff Clune. Illuminating search spaces by mapping elites. *arXiv preprint arXiv:1504.04909*, 2015.
- [10] Craig W. Reynolds. Steering behaviors for autonomous characters. In *Proceedings of the Game Developers Conference (GDC)*, volume 1999, pages 763–782, 1999.
- [11] Pieter Spronck, Marc Ponsen, Ida Sprinkhuizen-Kuyper, and Eric Postma. Adaptive game AI with evolutionary dynamic scripting. *Machine Learning*, 63(3):217–248, 2006.
- [12] Kenneth O. Stanley and Risto Miikkulainen. Evolving neural networks through augmenting topologies. *Evolutionary Computation*, 10(2):99–127, 2002.
- [13] Ke Wang and Ah-Hwee Tan. A self-organizing neural network approach for dynamic gameplay in target shooting games. *IEEE Transactions on Computational Intelligence and AI in Games*, 7(1):83–94, 2014.